

双稳健估计：从 AIPW 到 Bang & Robins 再到 TMLE

Doubly Robust Estimation: From AIPW to Plug-in Estimators and TMLE

Guo Wei

Department of Health Statistics, NMU

2026 年 6 月 26 日

问题设定与识别

目标： 估计二值处理 $A \in \{0, 1\}$ 对结果 Y 的平均因果效应 (ATE)

$$\psi = E[Y^1] - E[Y^0]$$

基本假设（可识别性）：

- **可交换性（Exchangeability）：** $Y^a \perp\!\!\!\perp A \mid L$
- **正定性（Positivity）：** $0 < \Pr[A = 1 \mid L = l] < 1, \quad \forall l$
- **一致性（Consistency）：** $Y = AY^1 + (1 - A)Y^0$

两个核心 nuisance functions：

$$b(a, L) = E[Y \mid A = a, L], \quad \pi(L) = \Pr[A = 1 \mid L]$$

传统方法 I: 结果回归 (g-formula / Standardization)

思想: 通过条件期望积分, 模拟对所有人施加同一处理

$$E[Y^a] = \int E[Y \mid A = a, L = l] dF_L(l) = E[b(a, L)]$$

插件估计量 (Plug-in):

$$\hat{\psi}_{\text{reg}} = \frac{1}{n} \sum_{i=1}^n \hat{b}(1, L_i) - \frac{1}{n} \sum_{i=1}^n \hat{b}(0, L_i)$$

局限:

- 一致性**完全依赖**结果模型 $b(a, L)$ 的正确设定
- 若模型误设 (遗漏非线性项、交互项), 估计量**不一致**

传统方法 II：逆概率加权（IPW）

思想： 通过逆概率加权，构造伪随机化总体

$$E[Y^a] = E\left[\frac{I(A=a) Y}{\Pr[A=a | L]}\right]$$

Horvitz-Thompson 估计量：

$$\hat{\psi}_{\text{IPW}} = \frac{1}{n} \sum_{i=1}^n \frac{A_i Y_i}{\hat{\pi}(L_i)} - \frac{1}{n} \sum_{i=1}^n \frac{(1 - A_i) Y_i}{1 - \hat{\pi}(L_i)}$$

局限：

- 一致性完全依赖处理模型 $\pi(L)$ 的正确设定
- 若倾向得分估计不准（尤其接近 0 或 1 时），方差爆炸、偏差增大

单稳健性的困境

方法	依赖模型	若该模型错误
结果回归	$b(a, L)$	不一致
IPW	$\pi(L)$	不一致

核心矛盾： 两种方法各押一注，研究者只有一次“猜对”的机会。

问题： 能否构造一个估计量，同时利用两个模型，且只要其中一个正确就能保持一致？

双稳健估计的直观思想

定义 (Doubly Robust): 一个估计量被称为双稳健的, 如果它在以下两种情形中 (至少) 一种是
一致的:

- ① 结果模型 $b(a, L)$ 正确设定 (无论 $\pi(L)$ 是否错误);
- ② 处理模型 $\pi(L)$ 正确设定 (无论 $b(a, L)$ 是否错误)。

且研究者**无需知道**哪个模型是正确的。

关键洞察: 双稳健估计量的渐近偏差通常形如两个模型误差的乘积。

$$\text{Bias} \propto (\text{结果模型误差}) \times (\text{处理模型误差})$$

增广 IPW 估计量 (AIPW)

Technical Point 13.2 的核心构造:

对反事实均值 $E[Y^{a=1}]$, AIPW 估计量为:

$$\hat{E}[Y^{a=1}]_{\text{DR}} = \frac{1}{n} \sum_{i=1}^n \left[\hat{b}(1, L_i) + \frac{A_i}{\hat{\pi}(L_i)} (Y_i - \hat{b}(1, L_i)) \right]$$

直观解读:

- 第一项 $\hat{b}(1, L_i)$: 结果回归的“基准预测”
- 第二项 $\frac{A_i}{\hat{\pi}(L_i)} (Y_i - \hat{b}(1, L_i))$: 用逆概率加权的残差进行修正

AIPW 的两种等价形式

形式 I (结果回归 + 加权残差):

$$\widehat{E}[Y^{a=1}]_{\text{DR}} = \frac{1}{n} \sum_{i=1}^n \left[\widehat{b}(1, L_i) + \frac{A_i}{\widehat{\pi}(L_i)} (Y_i - \widehat{b}(1, L_i)) \right]$$

形式 II (IPW - 加权预测修正):

$$\widehat{E}[Y^{a=1}]_{\text{DR}} = \frac{1}{n} \sum_{i=1}^n \left[\frac{A_i Y_i}{\widehat{\pi}(L_i)} - \left(\frac{A_i}{\widehat{\pi}(L_i)} - 1 \right) \widehat{b}(1, L_i) \right]$$

形式 II 显示: AIPW 可视为对经典 IPW 估计量的“修正”——用结果模型的预测值去抵消 IPW 的过度变异。

为什么 AIPW 是双稳健的?——数学核心

渐近偏差分解 (Technical Point 13.2):

$$\widehat{E}[Y^{a=1}]_{\text{DR}} - E[Y^{a=1}] \xrightarrow{P} E\left[\pi(L) \left(\frac{1}{\pi(L)} - \frac{1}{\pi^*(L)}\right) (b(L) - b^*(L))\right]$$

其中 $\pi^*(L)$ 和 $b^*(L)$ 分别是两个参数模型的概率极限。

核心观察: 偏差 = 处理模型误差 $\times$ 结果模型误差

- 若 $b^*(L) = b(L)$ (结果模型正确), 则偏差 = 0
- 若 $\pi^*(L) = \pi(L)$ (处理模型正确), 则偏差 = 0

结论: 只要两个模型中有一个正确, 估计量一致。这就是二阶偏差 (Second-Order Bias)。

二阶偏差：从“叠加”到“相乘”

单稳健估计量（一阶偏差）：

若 nuisance estimator 的误差为 $O_p(n^{-\alpha})$ （例如 $\alpha = 1/4$ ），则

$$\text{Bias}_{\text{IPW}} \approx E \left[\left(\frac{1}{\hat{\pi}} - \frac{1}{\pi} \right) AY \right] = O_p(n^{-\alpha})$$

当 $\alpha = 1/4$ 时，偏差为 $O_p(n^{-1/4})$ ，慢于 $\sqrt{n}$ 一致性所需的 $O_p(n^{-1/2})$ ，导致不一致。

双稳健估计量（二阶偏差）：

若结果模型误差 $O_p(n^{-\beta})$ ，处理模型误差 $O_p(n^{-\alpha})$ ，则

$$\text{Bias}_{\text{DR}} = O_p(n^{-\alpha}) \times O_p(n^{-\beta}) = O_p(n^{-(\alpha+\beta)})$$

关键阈值： 当 $\alpha = \beta = 1/4$ 时，

$$\text{Bias}_{\text{DR}} = O_p(n^{-1/2}) \quad (\text{刚好达到 } \sqrt{n}\text{-一致性!})$$

直观： 两个 10% 的误差，叠加仍是 10%，但相乘只有 1%。

从 AIPW 到插件估计量——关键分解

对 ATE，将两个 AIPW 估计量相减并整理 (Technical Point 13.3)：

$$\hat{\psi}_{1,\text{AIPW}} - \hat{\psi}_{0,\text{AIPW}} = \underbrace{P_n[\hat{b}(1, L)] - P_n[\hat{b}(0, L)]}_{\text{插件估计量}} - \underbrace{P_n \left[\frac{Y - \hat{b}(A, L)}{\hat{f}(A|L)} \{I(A=1) - I(A=0)\} \right]}_{\text{修正项 } \Delta}$$

关键问题： 如果能让修正项 $\Delta = 0$ ，则纯插件估计量 $P_n[\hat{b}(1, L)] - P_n[\hat{b}(0, L)]$ 将精确等于 AIPW 估计量！

Bang & Robins (2005) 的精妙之处： 通过一种特定的结果模型拟合方式，可以强制 $\Delta = 0$ ，从而让一个看似普通的回归插件估计量继承双稳健性。

Fine Point 13.2 的操作步骤:

① 估计 IP 权重: $W^A = 1/\hat{f}(A|L)$

② 构造辅助变量:

$$R = W^A \text{ if } A = 1, \quad R = -W^A \text{ if } A = 0$$

等价于:

$$R = \frac{A}{\hat{\pi}(L)} - \frac{1-A}{1-\hat{\pi}(L)}$$

③ 拟合结果回归: 用 canonical link 的 GLM 拟合 $E[Y | A, L, R]$

④ 标准化预测: 对所有人分别设 $A = 1$ 和 $A = 0$, 求预测均值之差

表面看: 带额外协变量 R 的结果回归, 然后做 g-computation。

实际上: 由于 R 的特殊构造, 该估计量是**双稳健**的。

技术核心 I: Clever Covariate 与模型设定

将变量 R 重新写成 **Clever Covariate** (Technical Point 13.3):

$$H(A, L) = \frac{I(A=1) - I(A=0)}{\hat{f}(A|L)} = \frac{A}{\hat{\pi}(L)} - \frac{1-A}{1-\hat{\pi}(L)}$$

模型设定 (Canonical Link GLM):

$$E[Y | A, L] = \phi[m(A, L; \beta) + \theta \cdot H(A, L)]$$

其中 $\phi[\cdot]$ 为 canonical link 的逆函数 (identity, logit, log 等)。

为什么必须是 canonical link?

因为在 canonical link 下, GLM 对协变量 X_j 的得分方程具有最简形式:

$$\sum_{i=1}^n X_{ij} (Y_i - \hat{\mu}_i) = 0$$

非 canonical link 下会出现额外的 $V(\mu)$ 和 $\partial\mu/\partial\eta$ 项, 无法直接对应 AIPW 修正项。

技术核心 II: 得分方程的魔力

对 clever covariate $H(A, L)$ 的系数 θ 求解得分方程:

$$\sum_{i=1}^n H(A_i, L_i)(Y_i - \hat{b}(A_i, L_i)) = 0$$

代入 $H(A, L)$ 的定义:

$$\sum_{i=1}^n \frac{I(A_i = 1) - I(A_i = 0)}{\hat{f}(A_i|L_i)} (Y_i - \hat{b}(A_i, L_i)) = 0$$

这正是 Slide 11 中的修正项 Δ !

因此:

- 通过 IRLS (或任何求解 canonical link GLM 得分方程的方法) 拟合该模型
- 收敛时自动满足 $\Delta = 0$
- 插件估计量 $P_n[\hat{b}(1, L)] - P_n[\hat{b}(0, L)]$ 精确等于 AIPW 估计量
- Bang & Robins 的插件估计量隐式地求解了 AIPW 的估计方程

从特例到一般框架：TMLE

Bang & Robins 方法的局限：

- 要求结果模型必须是参数化 GLM
- 要求一次性将 clever covariate 作为协变量纳入模型
- 在高维或复杂场景下（机器学习方法），无法直接套用

Targeted Minimum Loss Estimation (TMLE) 的两步架构：

步骤	任务	方法
Step 1	估计 nuisance $b(A, L)$ 和 $\pi(L)$	任意方法 (Super Learner, ML...)
Step 2	用一维参数 ϵ 和 clever covariate 修正	参数化子模型 (fluctuation model)

关键： 初始估计与靶向更新解耦。复杂拟合交给机器学习，因果修正交给低维参数。

为什么 TMLE 需要两步而非一步到位？

理由 1：兼容机器学习

现代机器学习方法（梯度提升、深度学习）不是参数化 GLM，无法像 Bang & Robins 那样直接把 $H(A, L)$ 当作协变量“塞进”模型联合优化。

理由 2：数值稳定性

Clever covariate 包含 $1/\hat{\pi}(L)$ ，在极端倾向得分下会爆炸。TMLE 先让初始估计吸收主要信号，再用残差 $Y - \hat{b}_{\text{init}}$ 做小幅靶向修正，避免优化灾难。

理由 3：半参数效率性

若 nuisance estimators 收敛速度达到 $n^{-1/4}$ （ML + 交叉验证可实现），TMLE 能达到半参数效率界。

理由 4：模块化与通用性

TMLE 不依赖于特定的损失函数或模型族。只要初始估计足够好，clever covariate 就能将其“靶向”修正为双稳健且有效的估计量。

统一视角：三种方法的共同本质

三种方法外表迥异，但共享同一个核心机制：

$$\text{插件估计量} - \text{修正项} = 0 \iff \text{双稳健性成立}$$

方法	让修正项归零的路径
AIPW	显式构造 ：直接写出加权残差修正项，使其在估计方程中自然抵消
Bang & Robins	隐式强制 ：通过 canonical link GLM 的得分方程，将修正项作为 clever covariate 的估计方程强制归零
TMLE	靶向更新 ：先用任意方法得到初始估计，再通过波动模型和最小损失投影，使修正项在更新后为零

不同的路径，同一个终点： 偏差 = 结果误差 × 处理误差。

总结

概念	核心要点
单稳健 二阶偏差	结果回归或 IPW 只依赖一个正确模型，偏差为一阶 双稳健估计量的偏差是两个 nuisance 误差的乘积，即使各为 $n^{-1/4}$ ，乘积可达 $n^{-1/2}$
AIPW Bang & Robins	显式加权形式，直接展示结果回归与 IPW 的加权残差修正 通过 canonical link GLM + clever covariate， 隐式 求解 AIPW 方程，得到双稳健插件估计量
TMLE	将双稳健思想推广到任意初始估计（尤其是机器学习），通过两步法保证双稳健与半参数效率

最终信息：

双稳健估计的本质不是“两个模型取平均”，而是**通过估计方程的精巧构造，使偏差成为两个 nuisance 估计误差的乘积**。无论是 AIPW 的显式加权形式、Bang & Robins 的隐式插件形式，还是 TMLE 的两步更新框架，它们共享同一个数学灵魂——**二阶偏差**。

- Hernán, M. A., & Robins, J. M. (2025). *Causal Inference: What If?* (2nd ed.). CRC Press. Chapter 13, Fine Point 13.2, Technical Points 13.2–13.3.
- Bang, H., & Robins, J. M. (2005). Doubly robust estimation in missing data and causal inference models. *Biometrics*, 61(4), 962–973.
- van der Laan, M. J., & Rubin, D. B. (2006). Targeted maximum likelihood learning. *UC Berkeley Division of Biostatistics Working Paper Series*.
- Robins, J. M., Rotnitzky, A., & Zhao, L. P. (1994). Estimation of regression coefficients when some regressors are not always observed. *JASA*, 89(427), 846–866.